

Sveučilište Jurja Dobrile u Puli
Fakultet informatike u Puli

Analiza podataka o letovima njujorških aerodroma

Seminarski rad

JMBAG: 0303110630

Studijski smjer: Informatika

Kolegij: Skladištenje i rudarenje podataka

Mentor: doc.dr.sc. Goran Oreški

Pula, 2025. godine

Sadržaj:

1. Uvod.....	4
2. Poslovna inteligencija	5
2.1. Skladište podataka.....	5
2.2. Poslovna analitika	6
2.3. Fokus na deskriptivnu analitiku	6
3. Otkrivanje i analiza dataset-a	7
3.1. Opis poslovnog problema	7
3.2. Cilj analize	8
3.2.1. Specifični ciljevi.....	8
3.2.2. Eksplorativna analiza podataka.....	8
4. Dizajn i implementacija relacijskog modela	11
4.1. Priprema i podjela podataka	11
4.2. Analiza zahtjeva i poslovnih pravila	12
4.3. Konceptualni model (ER dijagram).....	13
4.4. Relacijski model baze podataka	15
4.4.1. Struktura relacijskog modela	16
4.4.2. Veze i kardinalnosti	17
4.4.3. Normalizacija i stabilnost modela	17
4.5. Implementacija baze u MySQL-u	18
5. Dimenzijski model podataka	20
5.1. Osnove dimenzijskog modeliranja	20
5.2. Izrada zvjezdastog (star) modela.....	21
6. ETL proces	23
6.1. Tablica činjenica "fact_flight"	23
6.2. Dimenzijska tablica "dim_date"	24
6.3. Dimenzijska tablica "dim_time"	25
6.4. Dimenzijska tablica "dim_airline"	26
6.5. Dimenzijska tablica "dim_aircraft"	27

6.6. Dimenzijska tablica "dim_dep_delay"	28
6.7. Dimenzijska tablica "dim_arr_delay"	29
6.8. Dimenzijska tablica "dim_route"	30
7. Vizualizacija i poslovna analiza	31
7.1. Dashboard #1 – analiza letova po aviokompanijama	32
7.2. Dashboard #2 – OLAP operacije SLICE i DICE	36
7.3. Dashboard #3 – OLAP operacije: ROLL-UP i DRILL-DOWN	39
7.4. Dashboard #4 – Operacija PIVOT	42
7.5. Dashboard #5 – detaljna analiza letova po aviokompanijama	43
7.6. Dashboard #6 – Aviokompanije i sezonski trendovi	45
7.7. Dashboard #7 – Analiza operativnih performansi	47
7.8. Dashboard #8 – Geografska analiza destinacija s interaktivnim filtriranjem.....	50
8. Zaključak	52
9. Literatura	53

1. Uvod

Danas kao danas podatci su postali ključni resurs za uspješno poslovanje. Bez kvalitetno prikupljenih i analiziranih informacija teško je donositi utemeljene poslovne odluke.

U zrakoplovnoj industriji, gdje se svakodnevno obrađuju milijuni podataka o letovima, putnicima i operativnim procesima, potreba za učinkovitom pohranom i analizom podataka postaje presudna za uspjeh. U okviru kolegija *Skladištenje i rudarenje podataka* izradio sam projekt koji prikazuje cjelokupan proces izgradnje sustava za analizu i izvještavanje temeljenog na stvarnom skupu podataka o letovima iz New Yorka. Tijekom izrade projekta razvio sam snažno zanimanje za ovo područje jer omogućuje dobivanje korisnih uvida iz velikih količina podataka, poput prepoznavanja problema s kašnjenjima letova ili optimizacije operativne učinkovitosti. Za potrebe ovog rada koristio sam skup podataka o letovima s tri glavna njujorška aerodroma: John F. Kennedy International Airport (JFK), LaGuardia Airport (LGA) i Newark Liberty International Airport (EWR). Dataset obuhvaća 261.877 zapisa iz 2013. godine te uključuje detaljne informacije o vremenima polaska i dolaska, kašnjenjima, rutama i drugim operativnim parametrima. U projektu su korišteni alati koje smo koristili tijekom kolegija: Python, MySQL, Apache Spark i Power BI. Cilj je bio demonstrirati kako sa pravilnom obradom podataka možemo otkriti vrijedne obrasce i trendove koji pomažu aviokompanijama i aerodromskim operaterima u donošenju boljih poslovnih odluka.

2. Poslovna inteligencija

Poslovna inteligencija pretvara sirove podatke u korisne informacije koje pomažu u donošenju odluka i poduzimanju konkretnih poslovnih koraka.

U zrakoplovstvu, to znači da se podaci o letovima mogu iskoristiti za analizu kašnjenja, poboljšanje ruta i učinkovitije upravljanje resursima.

Sustav poslovne inteligencije ima **4 glavne komponente**:

Skladište podataka - centralno mjesto za pohranu podataka iz različitih izvora

Poslovna analitika - alati za analizu i tumačenje podataka

Upravljanje poslovnim performansama - praćenje ključnih pokazatelja uspješnosti (KPI)

Korisničko sučelje - praćenje ključnih pokazatelja uspješnosti (KPI)

2.1. Skladište podataka

Skladište podataka (Data Warehouse) je centralizirani sustav koji integrira podatke iz više izvora u jedinstven, konzistentan i vremenski orijentiran oblik.

Skladište podataka je:

Subjektivno orijentirano to znači da je organizirano prema poslovnim entitetima (npr. letovi, aviokompanije)

Integrirano to znači da je usklađeno među izvorima podataka

Postojano to znači da se podaci ne mijenjaju nakon učitavanja

Vremenski varijantno to znači da omogućuje analizu kroz vremenske periode

Arhitektura skladišta tipično uključuje slojeve za ekstrakciju, staging, skladište podataka i prezentacijske slojeve (npr. dashboarde).

2.2. Poslovna analitika

Poslovna analitika predstavlja sustavno istraživanje podataka s ciljem donošenja informiranih odluka. Ona se dijeli u tri osnovne kategorije:

Deskriptivna analitika (što se dogodilo) - analiza historijskih podataka za razumijevanje prošlih događaja kroz izvještaje i KPI pokazatelje.

Prediktivna analitika (što će se dogoditi) - korištenje historijskih podataka i statističkih modela za predviđanje budućih trendova.

Preskriptivna analitika (što treba poduzeti) - preporuča optimalne akcije koristeći optimizacijske algoritme i simulacije.

2.3. Fokus na deskriptivnu analitiku

U ovom projektu naglasak je stavljen na deskriptivnu analitiku koja omogućava detaljnu analizu povijesnih obrazaca u podacima o letovima. Konkretno, analizirani su sljedeći aspekti:

Operativne performanse: identifikacija aerodroma s najviše kašnjenja, analiza sezonskih trendova, praćenje performansi zrakoplovnih kompanija.

Vremenske obrasce: utjecaj doba godine na performanse, najproblematičniji dani u tjednu, vremena dana s najvećim kašnjenjima.

Rute i destinacije: najfrekventnije rute iz NYC aerodroma, analiza udaljenosti letova, najpopularnije destinacije.

Cjelokupna analiza provodi se kroz skladište podataka s implementiranim ETL procesom za čišćenje i transformaciju podataka, a konačni rezultati vizualizirani su pomoću Power BI-a.

3. Otkrivanje i analiza dataset-a

Za potrebe ovog projekta odabrao sam dataset letova preuzet s Kaggle platforme (<https://www.kaggle.com/datasets/mahoora00135/flights>). Skup podataka sadrži evidenciju svih letova iz tri glavna newyorška aerodroma tijekom 2013. godine. Odabrao sam ovaj dataset jer sadrži podatke o letovima koji odražavaju situacije s kojima se susreću stvarne aviokompanija i aerodromi.

Osnovne karakteristike dataset-a:

Ukupno zapisa: 261,877 letova

Vremenski period: 2013. godina (cijela godina)

Geografski opseg: Tri glavna NYC aerodroma (JFK, LaGuardia, Newark)

Broj atributa: 29 stupaca s različitim tipovima podataka

Format datoteke: CSV

3.1. Opis poslovnog problema

New York je jedno od najprometnijih zračnih čvorišta na svijetu, s tisućama letova koji svakodnevno polaze s tri ključna aerodroma: John F. Kennedy International (JFK), LaGuardia (LGA) i Newark Liberty International (EWR). Svaki let u ovom sustavu definiran je kombinacijom aviokompanije, registracije zrakoplova (tailnum), specifične rute te planiranih i stvarnih vremena polaska i dolaska.

Poznavanje stvarnog i planiranog vremena omogućuje precizno izračunavanje kašnjenja, dok dodatni podaci otkrivaju uzroke tih kašnjenja – bilo da se radi o tehničkim problemima, vremenskim uvjetima, operativnim izazovima ili zagušenju zračnog prostora. Uz to, svaki let nosi podatke o udaljenosti i stvarnom trajanju, što omogućava dublju analizu efikasnosti letova.

3.2. Cilj analize

Glavni cilj projekta je izraditi analitičko sučelje namijenjeno menadžerima aerodroma i aviokompanija u području New Yorka. Sučelje će im omogućiti brže, informiranije i učinkovitije donošenje poslovnih odluka temeljenih na stvarnim operativnim podacima.

3.2.1. Specifični ciljevi

Identificirati glavne uzroke kašnjenja i njihove obrasce kroz vrijeme

Analizirati performanse različitih aviokompanija u odnosu na punctualnost

Optimizirati rasporede letova na temelju povijesnih podataka o prometu

Poboljšati planiranje kapaciteta aerodroma kroz analizu sezonskih trendova

Pružiti uvide za strateško planiranje ruta i operativnih procesa

3.2.2. Eksplorativna analiza podataka

Kao početni korak, izradio sam skriptu *analiza.py*, koja automatizira osnovnu eksplorativnu analizu. Skripta nam pruža pregled strukture i kvalitete podataka, te omogućava identifikaciju potencijalnih problema već u početnoj fazi projekta.


```

import pandas as pd
import os

# Definirali smo relativnu putanju do datoteke
datoteka = os.path.join(os.path.dirname(__file__), "flights_main.csv")

# Učitali smo podatke iz CSV datoteke
data = pd.read_csv(datoteka, encoding="utf-8")

# Prikazali smo osnovne informacije o podacima
print(data.head())
print("Veličina skupa podataka:", data.shape)
print(["Nazivi stupaca:", data.columns.tolist()])

# Provjerili smo nedostajuće vrijednosti
print("Nedostajuće vrijednosti po stupcu:")
print(data.isna().sum())

# Ispisali smo jedinstvene vrijednosti za svaki stupac
print("Jedinstvene vrijednosti po stupcu:")
for column in data.columns:
    print(f"{column}: {data[column].unique()[:10]} ...")

# Provjerili smo tipove podataka
print(data.dtypes)

# Analizirali smo frekvencije vrijednosti po stupcima
print("Frekvencije vrijednosti po stupcu:")
for column in data.columns:
    print(f"{column}:")
    print(data[column].value_counts(), "\n")

```

Slika 1. Početna analiza dataseta

U skripti *analiza.py* proveo sam početnu analizu podataka kako bih osigurao njihovu kvalitetu i pripremio ih za daljnju obradu. Najprije sam učitao podatke iz izvornog CSV dokumenta koristeći odgovarajući encoding (UTF-8), kako bih omogućio ispravno očitavanje svih znakova. Nakon toga prikazao sam osnovne statistike, uključujući dimenzije skupa podataka i pregled prvih nekoliko redaka, što mi je omogućilo brzi pregled structure podataka. Nakon toga provjerio sam kvalitetu podataka tražeći nedostajuće vrijednosti u stupcima. Analizirao sam kako su podaci raspoređeni i koliko se često određene vrijednosti pojavljuju. Na kraju sam provjerio jesu li tipovi podataka ispravni, odnosno odgovaraju li očekivanim formatima kao što su brojevi, tekst ili datumi. Ova analiza bila mi je važna za pripremu podataka za daljnju obradu i vizualizaciju.

Nedostajuće vrijednosti po stupcu:		Jedinstvene vrijednosti po stupcu:	
id	0	id:	[0 1 2 3 4 5 7 9 10 11] ...
year	0	year:	[2013] ...
month	0	month:	[1 10 11 12 2 3 4 5 6 7] ...
day	0	day:	[1 2 3 4 5 6 7 8 9 10] ...
day_of_week	0	day_of_week:	['Tuesday' 'Wednesday' 'Thursday' 'Friday' 'Saturday' 'Sunday' 'Monday'] ...
dep_time	0	dep_time:	['05:17' '05:33' '05:42' '05:44' '05:54' '05:57' '05:58' '05:59' '06:00' '06:02'] ...
sched_dep_time	0	sched_dep_time:	['05:15' '05:29' '05:40' '05:45' '06:00' '05:58' '05:59' '06:05' '06:10' '06:15'] ...
dep_delay_time	0	dep_delay_time:	[2. 4. -1. -6. -4. -3. -2. 0. 8. 11.] ...
reason_dep_delay	0	reason_dep_delay:	['Slow Ground Operations' 'Ground Crew Coordination' 'Taxiing Delay' 'Early Departure' 'On Time' 'Baggage Handling Delay' 'Gate Change' 'Minor Technical Delays' 'De-icing Process' 'Air Traffic Congestion'] ...
arr_time	0	arr_time:	['08:30' '08:50' '09:23' '10:04' '08:12' '07:40' '07:09' '07:53' '08:49' '08:53'] ...
sched_arr_time	0	sched_arr_time:	['08:19' '08:30' '08:50' '10:22' '08:37' '07:28' '07:23' '07:45' '08:51' '08:56'] ...
flight_num	0	flight_num:	[1545 1714 1141 725 461 1696 5708 301 49 71] ...
tailnum	0	tailnum:	['N14228' 'N24211' 'N619AA' 'N804JB' 'N668DN' 'N39463' 'N829AS' 'N3ALAA' 'N793JB' 'N657JB'] ...
origin	0	origin:	['EWR' 'LGA' 'JFK'] ...
destination	0	destination:	['IAH' 'MIA' 'BQN' 'ATL' 'ORD' 'IAD' 'PBI' 'TPA' 'LAX' 'BOS'] ...
air_time	0	air_time:	[227. 160. 183. 116. 150. 53. 138. 149. 158. 345.] ...
distance	0	distance:	[1400 1416 1089 1576 762 719 229 733 1028 1005] ...
hour	0	hour:	[5 6 7 8 18 9 10 11 12 13] ...
minute	0	minute:	[15 29 40 45 0 58 59 5 10 30] ...
airline_name	0	airline_name:	['United Air Lines Inc.' 'American Airlines Inc.' 'JetBlue Airways'] ...
departure_city	0		
departure_country	0		
departure_airport_name	0		
destination_city	0		
destination_country	0		
destination_airport_name	0		

Slika 2. Rezultati nedostajućih i jedinstvenih vrijednosti po stupcu

4. Dizajn i implementacija relacijskog modela

4.1. Priprema i podjela podataka

Prilikom pripreme podataka za izradu relacijskog modela, glavni CSV skup podataka podijelio sam na dva dijela: 80% podataka koristio sam za dizajn, implementaciju i inicijalno punjenje svih tablica u relacijskoj bazi, te sam time osigurao da su svi entiteti i odnosi ispravno definirani te da baza sadrži dovoljno podataka za analizu operativnih procesa u zrakoplovstvu. Preostalih 20% izdvojio sam za potrebe provjere ispravnosti ETL procesa i testiranje performansi baze podataka. Također, koristim ih kao neovisan skup za validaciju analitičkih modela i izvještaja. Na taj način mogu detektirati potencijalne probleme u obradi novih podataka, što povećava pouzdanost cijelog sustava.

Prije nego što sam implementirao relacijski model, predprocesiro sam sirove podatke pomoću skripte *predproc.py*:

```
CSV_FILE_PATH = "flights_main.csv" # Odredili smo putanju do CSV datoteke

df = pd.read_csv(CSV_FILE_PATH, delimiter=',') # Učitali smo podatke i ispisali dimenzije
print("CSV size before: ", df.shape)

# Standardizirali smo nazive zemalja
df['departure_country'] = df['departure_country'].replace('USA', 'United States')
df['destination_country'] = df['destination_country'].replace('USA', 'United States')
df['departure_country'] = df['departure_country'].replace('UK', 'United Kingdom')
df['destination_country'] = df['destination_country'].replace('UK', 'United Kingdom')

df = df.dropna() # Uklonili smo redove s nedostajućim vrijednostima

# Standardizacija naziva stupaca
df.columns = df.columns.str.lower()
df.columns = df.columns.str.replace(' ', '_')

print("CSV size after: ", df.shape)
print(df.head())

duplicates = df.duplicated().sum() # Provjerili smo postojanje duplikata
print(f"Number of duplicates: {duplicates}")

if duplicates > 0: # Uklonili smo duplikate ako postoje
    df = df.drop_duplicates()
    print(f"CSV size after removing duplicates: {df.shape}")

# Podijelili smo podatke na 80:20
df20 = df.sample(frac=0.2, random_state=1)
df80 = df.drop(df20.index)

print("CSV size 80: ", df80.shape)
print("CSV size 20: ", df20.shape)

# Spreмили smo obrađene podatke u nove datoteke
df80.to_csv("flights_processed_80.csv", index=False)
df20.to_csv("flights_processed_20.csv", index=False)
```

Slika 3. Skripta za predprocesuaciju skupa podataka i podjelu na 80:20

```

$ python predproc.py
CSV size before: (261877, 29)
CSV size after: (261877, 29)
   id  year  month  day  ...  departure_airport_name de
0   0  2013     1    1  ...  Newark Liberty International Airport
1   1  2013     1    1  ...  LaGuardia Airport
2   2  2013     1    1  ...  John F Kennedy International Airport
3   3  2013     1    1  ...  John F Kennedy International Airport
4   4  2013     1    1  ...  LaGuardia Airport

[5 rows x 29 columns]
Number of duplicates: 0
CSV size 80: (209502, 29)
CSV size 20: (52375, 29)

Predprocesiranje završeno!
Stvorene datoteke:
- flights_processed_80.csv (80% podataka za transakcijski model)
- flights_processed_20.csv (20% podataka za ETL direktno iz CSV-a)

```

Slika 4. Prikaz podataka prije i poslije predprocesiranja

4.2. Analiza zahtjeva i poslovnih pravila


Sljedeći korak u izradi relacijskog modela bio je da detaljno pregledam poslovne zahtjeve i pravila vezana uz skup podataka Flights. Nakon što sam proučio izvorne podatke, identificirao sam glavne entitete s kojima ću raditi: aviokompanije, avione, letove, rute, kašnjenja polaska i kašnjenja dolaska. Svaki od tih entiteta važan je za operativni proces.

Zatim sam definirao pravila koja određuju kako su ti entiteti povezani. Na primjer, ustanovio sam da svaka aviokompanija može imati više aviona tijekom vremena, što je logično jer tvrtke posjeduju različite flote. Također, svaki avion može obaviti više letova dnevno, jer se avioni koriste za različite rute tijekom dana. Svaki let ide određenom rutom između dva aerodroma i može imati različite razloge kašnjenja polaska i dolaska.

Posebno sam pazio na integritet podataka kako bih spriječio unošenje netočnih ili nekonzistentnih podataka u bazu. Zato sam postavio pravila koja, na primjer, ne dozvoljavaju kreiranje leta ako ne postoji odgovarajuća aviokompanija ili dodavanje aviona s nevažećom registracijskom oznakom.

4.3. Konceptualni model (ER dijagram)

Na temelju analize zahtjeva izradio sam konceptualni model podataka korištenjem ER (Entity-Relationship) dijagrama. ER dijagram grafički prikazuje entitete, njihove atribute i veze među njima. Ključne entitete prikazao sam s pripadajućim atributima, dok sam odnose između entiteta jasno označio.



Slika 5. ER dijagram

Na slici je prikazan ER (Entity-Relationship) dijagram koji vizualno prikazuje glavne entitete, njihove atribute i odnose između njih u sklopu Flights baze podataka.

Entiteti i njihovi atributi:

Airline (aviokompanija)

Sadrži atribute *id*, *carrier* (IATA kod aviokompanija), *airline_name* (puno ime aviokompanija)

Aircraft (zrakoplov)

Sadrži attribute *id*, *tailnum* (registarska oznaka aviona), *airline_fk* (strani ključ prema entitetu *airline*)

Route (ruta)

Sadrži attribute *id*, *origin* (polazni aerodrom), *destination* (odredišni aerodrom), *departure_city*, *departure_country*, *departure_airport_name*, *destination_city*, *destination_country*, *destination_airport_name*, *distance* (udaljenost rute u miljama)

Flight (let)

Sadrži attribute *id*, *year*, *month*, *day*, *day_of_week*, *dep_time* (stvarno vrijeme polaska), *arr_time* (stvarno vrijeme dolaska), *sched_dep_time* (planirano vrijeme polaska), *sched_arr_time* (planirano vrijeme dolaska), *hour*, *minute*, *air_time* (vrijeme leta), *flight_num* (broj leta), *aircraft_fk* (strani ključ prema entitetu *aircraft*), *route_fk* (strani ključ prema entitetu *route*), *dep_delay_fk* (strani ključ prema entitetu *dep_delay*), *arr_delay_fk* (strani ključ prema entitetu *arr_delay*)

DepDelay (kašnjenje polaska)

Sadrži attribute *id*, *reason_dep_delay* (razlog kašnjenja polaska), *dep_delay_time* (vrijeme kašnjenja polaska u minutama)

ArrDelay (kašnjenje dolaska)

Sadrži attribute *id*, *reason_arr_delay* (razlog kašnjenja dolaska), *arr_delay_time* (vrijeme kašnjenja dolaska u minutama)

Odnosi među entitetima:

airline je povezan s *aircraft* (aviokompanija posjeduje flotu aviona)

aircraft može imati više *flight* zapisa (avion može letjeti više letova kroz dan)

route je povezana s više *flight* zapisa (ista ruta se koristi za više letova dnevno)

flight je povezan s *dep_delay* (let može imati kašnjenje polaska)

flight je povezan s *arr_delay* (let može imati kašnjenje dolaska)

flight povezuje sve entitete (let je centralni operativni proces koji uključuje aviokompaniju, avion, rutu i eventualna kašnjenja)


dep_delay može biti povezan s više flight zapisa (isti razlog kašnjenja se može pojaviti kod više letova)

arr_delay može biti povezan s više flight zapisa (isti razlog kašnjenja se može pojaviti kod više letova)

4.4. Relacijski model baze podataka

Nakon stvaranja konceptualnog (EER) dijagrama, sljedeći korak bio je definiranje relacijskog modela baze podataka. Trebao sam prevesti teoretski dizajn u konkretnu strukturu koju mogu implementirati u MySQL okruženju. Relacijski model predstavlja pristup organiziranja podataka gdje sam sve informacije strukturirao u odvojene tablice koje su povezane pomoću primarnih i stranih ključeva. Odabrao sam ovaj pristup jer osigurava stabilnost i konzistentnost podataka, što je ključno za pouzdanost operativnog sustava u zrakoplovstvu.

Tijekom definiranja modela pazio sam da svaka tablica ima jasno definirani primarni ključ i da su relacije između tablica logički utemeljene i efikasno dizajnirane. Ovakav pristup omogućio mi je stvaranje solidne osnove za kasniju implementaciju ETL procesa i analitičkih obrada.



Slika 6. Relacijski model baze podataka

4.4.1. Struktura relacijskog modela

Na temelju analize podataka i EER dijagrama stvorio sam relacijski model za Flights koji se sastoji od šest glavnih tablica:

airline: osnovni podaci o aviokompanijama (ID, IATA kod, ime).

aircraft: informacije o avionima i povezanost s aviokompanijom.

route: podaci o rutama – polazni i odredišni aerodromi, gradovi, zemlje i udaljenost.

dep_delay: razlozi i trajanje kašnjenja polaska.

arr_delay: razlozi i trajanje kašnjenja dolaska.

flight: povezuje sve tablice i sadrži podatke o letovima i vremenima. Sadrži temporalne podatke, vremena letova, brojeve letova i sve strane ključeve koji povezuju let s aviokompanijom, avionom, rutom i kašnjenjima.

Dizajnirao sam svaku tablicu s jasno definiranim primarnim ključem, a veze među tablicama uspostavio sam korištenjem stranih ključeva.

4.4.2. Veze i kardinalnosti

Veze između tablica u mom relacijskom modelu temelje se na poslovnim pravilima i kardinalnostima iz konceptualnog modela. One prikazuju stvarnu logiku u zrakoplovstvu:

Airline – Aircraft (1:N) – Jedna aviokompanija može imati više aviona. To omogućuje da jedna kompanija posjeduje cijelu flotu različitih letjelica.

Aircraft – Flight (1:N) – Svaki avion može imati više letova. To je u skladu s praksom da jedan avion leti više puta dnevno na različitim rutama.

Route – Flight (1:N) – Jedna ruta može biti povezana s više letova, što omogućuje da se ista ruta koristi više puta dnevno.

DepDelay – Flight (1:N) – Svaki razlog kašnjenja pri polasku može se odnositi na više letova, što omogućuje analizu uzroka kašnjenja.

ArrDelay – Flight (1:N) – Svaki razlog kašnjenja pri dolasku može biti vezan uz više letova, čime se omogućuje praćenje uzoraka dolaznih kašnjenja.

Tablica **Flight** predstavlja centralni entitet jer povezuje sve ostale tablice putem stranih ključeva i služi kao glavni operativni zapis u sustavu.


4.4.3. Normalizacija i stabilnost modela

Tijekom izrade relacijskog modela pridržavao sam se principa normalizacije kako bih smanjio višak podataka i osigurao stabilnost baze. Svaki tip informacije smjestio sam u zasebnu tablicu

kojoj logički pripada, umjesto da se isti podaci ponavljaju na više mjesta. Svaki entitet ima svoju jasno definiranu tablicu, a veze među njima ostvaruju se putem primarnih i stranih ključeva.

4.5. Implementacija baze u MySQL-u

Za implementaciju relacijskog modela koristio sam MySQL sustav za upravljanje bazama podataka. Proces je bio podijeljen u nekoliko faza – prvo sam definirao strukturu baze, zatim kreirao tablice prema modelu, a na kraju popunio bazu podacima iz pripremljenih CSV datoteka. Na temelju izrađenog relacijskog modela definirao sam sve potrebne tablice u MySQL-u. Svaka tablica sadrži jasno definirane primarne i strane ključeve, kako bih osigurao integritet i povezivost podataka. Struktura tablica odgovara entitetima iz mog EER dijagrama: **airline**, **aircraft**, **route**, **dep_delay**, **arr_delay** i **flight**.



```
checkpoint2 > stvaranje.py > ...
13 # Putanja do predprocesirane CSV datoteke (80% podataka)
14 CSV_FILE_PATH = "flights_processed_80.csv"
15
16 # Učitavanje CSV datoteke u dataframe
17 df = pd.read_csv(CSV_FILE_PATH, delimiter=',')
18 print(f"CSV size: {df.shape}") # Print dataset size
19 print(df.head()) # Preview first few rows
20
21 # Database Connection
22 Base = declarative_base()
23
24 # Definiranje sheme baze podataka
25 # -----
26 class Airline(Base):
27     __tablename__ = 'airline'
28     id = Column(Integer, primary_key=True, autoincrement=True)
29     carrier = Column(String(3), nullable=False, unique=True)
30     airline_name = Column(String(100), nullable=False)
31
32 class Aircraft(Base):
33     __tablename__ = 'aircraft'
34     id = Column(Integer, primary_key=True, autoincrement=True)
35     tailnum = Column(String(10), nullable=False, unique=True)
36     airline_fk = Column(Integer, ForeignKey('airline.id'))
37
38 class Route(Base):
39     __tablename__ = 'route'
40     id = Column(Integer, primary_key=True, autoincrement=True)
41     origin = Column(String(5), nullable=False)
42     destination = Column(String(5), nullable=False)
43     departure_city = Column(String(50))
44     departure_country = Column(String(50))
45     departure_airport_name = Column(String(100))
46     destination_city = Column(String(50))
47     destination_country = Column(String(50))
48     destination_airport_name = Column(String(100))
49     distance = Column(Float)
50
51 class DepDelay(Base):
52     __tablename__ = 'dep_delay'
53     id = Column(Integer, primary_key=True, autoincrement=True)
54     reason_dep_delay = Column(String(50))
55     dep_delay_time = Column(Float)
56
57 class ArrDelay(Base):
58     __tablename__ = 'arr_delay'
59     id = Column(Integer, primary_key=True, autoincrement=True)
60     reason_arr_delay = Column(String(50))
61     arr_delay_time = Column(Float)
62
63 class Flight(Base):
64     __tablename__ = 'flight'
65     id = Column(Integer, primary_key=True, autoincrement=True)
66     year = Column(Integer, nullable=False)
67     month = Column(Integer, nullable=False)
68     day = Column(Integer, nullable=False)
69     day_of_week = Column(String(10), nullable=False)
70     dep_time = Column(String(10))
71     arr_time = Column(String(10))
72     sched_dep_time = Column(String(10), nullable=False)
73     sched_arr_time = Column(String(10), nullable=False)
74     hour = Column(Integer)
75     minute = Column(Integer)
76     air_time = Column(Float)
77     flight_num = Column(Integer)
78     dep_delay_fk = Column(Integer, ForeignKey('dep_delay.id'))
79     arr_delay_fk = Column(Integer, ForeignKey('arr_delay.id'))
80     route_fk = Column(Integer, ForeignKey('route.id'))
81     aircraft_fk = Column(Integer, ForeignKey('aircraft.id'))
82
83 # Database Connection
84 engine = create_engine('mysql+pymysql://root:root@localhost:3306/flights_db', echo=False)
```

Slika 7. Definiranje sheme baze podataka

Za kreiranje tablica koristio sam SQL naredbe unutar Python skripte, što mi je omogućilo automatizaciju i ponovljivost cijelog procesa. Korištena je biblioteka **SQLAlchemy** za

povezivanje s bazom i za rad s podacima preko ORM-a.

Prvo sam se spojio na MySQL bazu pomoću pristupnih podataka.

Zatim sam prema relacijskom modelu kreirao sve potrebne tablice.

Nakon toga sam učitao podatke iz CSV datoteka u **DataFrame-ove**, uklonio duplikate i provjerio valjanost podataka.

Najzahtjevniji dio bio je unos podataka u tablice, jer je bilo važno poštivati pravilan redoslijed unosa zbog stranih ključeva. Na kraju sam provjerio jesu li svi podaci uspješno uneseni i jesu li veze među tablicama ispravno uspostavljene.

```
# **1. Umetanje aviokompanije**
airlines = df[['carrier', 'airline_name']].drop_duplicates() # Dohvatimo jedinstvene aviokompanije
airlines_list = airlines.to_dict(orient="records") # Pretvori u listu rječnika

session.bulk_insert_mappings(Airline, airlines_list) # Bulk insert
session.commit()

airline_map = {a.carrier: a.id for a in session.query(Airline).all()} # Stvori mapiranje aviokompanija
print(f"Uneseno {len(airlines_list)} aviokompanija")

# **2. Umetanje ruta**
routes = df[['origin', 'destination', 'departure_city', 'departure_country',
            'departure_airport_name', 'destination_city', 'destination_country',
            'destination_airport_name', 'distance']].drop_duplicates() # Dohvacamo jedinstvene rute

routes_list = routes.to_dict(orient="records") # Pretvori u listu rječnika

session.bulk_insert_mappings(Route, routes_list) # Bulk insert
session.commit()

# Kreiraj mapiranje ruta - kombinacija origin i destination
route_map = {}
for route in session.query(Route).all():
    key = f"{route.origin}_{route.destination}"
    route_map[key] = route.id

print(f"Uneseno {len(routes_list)} ruta")
```

Slika 8. Primjer punjenja tablice airlines, route

5. Dimenzijski model podataka

Za razliku od relacijskog modela, dimenzijski model predstavlja drugačiji način organizacije podataka. Koristi se za analizu i izvještavanje, jer omogućuje jednostavniji i brži pristup velikim količinama poslovnih informacija.

Ovdje mi je cilj omogućiti višedimenzionalni prikaz letnih operacija kroz različite aspekte koji su važni za razumijevanje poslovanja, uključujući:

Vrijeme – kada su letovi obavljeni

Aviokompanija – tko je operirao letove

Ruta – između kojih aerodroma

Avion – koja je letjelica korištena

Kašnjenje – razlozi i trajanje kašnjenja

5.1. Osnove dimenzijskog modeliranja

Dimenzijsko modeliranje je metoda organiziranja podataka tako da su strukturirani oko poslovnog procesa, a analitički upiti budu brzi i jednostavni.

U središtu modela nalazi se **tablica činjenica** koja sadržava sve numeričke vrijednosti koje analiziram, poput trajanja letova, vremena kašnjenja i udaljenosti. Uz te vrijednosti, tablica uključuje i strane ključeve koji vode prema povezanim dimenzijskim tablicama.

Dimenzijske tablice daju kontekst brojčanim podacima i sadrže opisne informacije, poput imena aviokompanija, registracijskih oznaka aviona, naziva aerodroma ili razloga kašnjenja. One su važne jer omogućuju detaljniju analizu kroz različite poslovne aspekte.

U sklopu dimenzija definirao sam i **hijerarhije** koje pomažu u grupiranju i agregaciji podataka.

U vremenskoj dimenziji postavio sam razine analize koje idu od godine, preko kvartala i mjeseca, do pojedinačnih dana. U geografskoj dimenziji hijerarhija ide od zemlje, zatim preko regije i grada, sve do konkretnih aerodroma.

5.2. Izrada zvjezdastog (star) modela

Nakon izrade relacijskog modela izradio sam dimenzijski model takozvanu star shemu. U ovom modelu tablica činjenica **Fact_Flights** koja se nalazi u središtu i tablica koja sadrži sve numeričke podatke - `air_time`, `dep_delay_time`, `arr_delay_time`, `distance`, a sve dimenzijske tablice povezane su izravno s njom.

Tablica **Dim_Airline** predstavlja dimenziju aviokompanija i sadrži informacije poput *carrier* koda i punog imena aviokompanije.

Tablica **Dim_Date** predstavlja vremensku dimenziju i uključuje attribute kao što su *godina*, *mjesec*, *dan*, *kvartal* i *dan u tjednu*, što omogućava vremensku analizu letova.


Tablica **Dim_Time** služi za detaljniji prikaz dnevnog vremena i sadrži *sate*, *minute* i kategorizaciju po dobu dana (npr. jutro, popodne, večer).

Tablica **Dim_Route** opisuje rutu leta i uključuje informacije o *polaznom i odredišnom aerodromu*, *gradovima*, *zemljama* i *udaljenostima* između destinacija.

Tablica **Dim_Aircraft** odnosi se na dimenziju zrakoplova i sadrži *registracijske oznake* (tailnum) svakog aviona korištenog u letu.

Tablice **Dim_DepDelay** i **Dim_ArrDelay** odnose se na dimenzije kašnjenja i uključuju *razloge kašnjenja* te *vrijeme kašnjenja* pri polasku i dolasku.

Za implementaciju koristio sam **SQLAlchemy** unutar Pythona.



Slika 9. Dimenzijski model podataka

6. ETL proces

ETL (Extract, Transform, Load) predstavlja ključni korak u izgradnji skladišta podataka. Cilj ovog procesa je prikupiti podatke iz različitih izvora, obraditi ih i pripremiti za analizu te ih na kraju učitati u bazu podataka u odgovarajućem obliku. Dobro osmišljen ETL osigurava da su podaci točni, usklađeni i ažurni, što je temelj za kvalitetnu poslovnu analitiku.

Implementirao sam ETL proces sam koristeći Apache Spark, koji mi je omogućio efikasnu obradu velike količine podataka o letovima. Proces sam podijelio u tri glavne faze. Prvo sam izveo ekstrakciju podataka iz izvora, što je uključivalo dohvaćanje podataka iz CSV datoteka. Zatim sam proveo transformaciju – u ovoj fazi obradio sam podatke tako da su očišćeni, normalizirani i obogaćeni dodatnim atributima potrebnima za analizu. Svaka dimenzijska tablica prošla je kroz zaseban postupak transformacije. Na kraju sam učitao obrađene podatke u bazu podataka, u skladu s prethodno definiranim dimenzijskim modelom.

6.1. Tablica činjenica "fact_flight"

Proces izgradnje tablice činjenica "fact_flight" započinje prikupljanjem svih kvantitativnih mjera i identifikatora potrebnih za povezivanje s dimenzijskim tablicama iz izvornih podataka o letovima. U ovoj fazi ekstrahiraju se ključne mjere poput vremena leta (air_time), brojeva letova (flight_num) te se pripremaju strani ključevi prema svim dimenzijskim tablicama. Nakon ekstrakcije, podaci prolaze kroz složenu transformaciju koja uključuje mapiranje stranih ključeva, izračun dodatnih mjera poput "scheduled_duration", "actual_duration" i "on_time_flag", te validaciju referencijalnog integriteta. Posebna pažnja posvećena je tehničkim atributima, poput surogat ključa (flight_tk), koji omogućavaju sveobuhvatnu analizu operativnih performansi kroz različite dimenzijske perspektive i osiguravaju konzistentnost podataka u cijelom dimenzijskom modelu.

18 • `SELECT * FROM fact_flight LIMIT 10;`

Result Grid

Filter Rows:

Export:

Wrap Cell Content:

Fetch rows:

	flight_tk	airline_id	aircraft_id	route_id	dep_delay_id	arr_delay_id	date_id	time_id	air_time	flight_num	scheduled_duration	actual_duration	on_time_flag
1	1	196	3	1000	1061	110	159253	119	5407	149	119	1	
2	1	196	3	1005	1779	211	232399	99	5092	129	99	1	
3	1	196	3	1000	1046	237	115566	92	5148	122	92	1	
4	1	196	3	1000	1062	279	131563	105	5156	135	105	1	
5	1	196	3	998	624	280	13367	107	4918	137	107	1	
6	1	196	25	998	1062	158	3437	90	5068	120	90	1	
7	1	196	25	1721	1061	161	5308	84	5559	114	84	1	
8	1	196	25	1339	1414	177	176168	81	5615	111	81	1	
9	1	196	25	1808	1524	190	229804	73	5454	103	73	1	
10	1	196	25	996	1037	209	64632	72	5222	102	72	1	

Slika 10. Tablica činjenica *fact_flight*

6.2. Dimenzijska tablica "dim_date"

Proces izgradnje vremenske dimenzije "dim_date" specifičan je jer se ne oslanja direktno na postojeće podatke, već se generira programski za potreban vremenski raspon. Dimenzija pokriva sve datume iz 2013. godine s dodatnim izvedenim atributima poput kvartala, naziva mjeseca, informacije o vikendu i sezonskim karakteristikama. Ova dimenzija omogućuje analizu kašnjenja, sezonskih promjena i operativnih trendova kroz različite vremenske periode.

15 • `SELECT * FROM dim_date LIMIT 10;`

	date_tk	year	month	day	day_of_week	quarter	month_name	is_weekend
1		2013	1	1	Tuesday	1	January	0
2		2013	1	2	Wednesday	1	January	0
3		2013	1	3	Thursday	1	January	0
4		2013	1	4	Friday	1	January	0
5		2013	1	5	Saturday	1	January	1
6		2013	1	6	Sunday	1	January	1
7		2013	1	7	Monday	1	January	0
8		2013	1	8	Tuesday	1	January	0
9		2013	1	9	Wednesday	1	January	0
10		2013	1	10	Thursday	1	January	0

Slika 11. Dimenzijska tablica *dim_date*

6.3. Dimenzijska tablica "dim_time"

Proces izgradnje dimenzijske tablice "dim_time" započinje prikupljanjem vremenskih komponenti iz izvornih podataka o letovima, uključujući planirane i stvarne termine polaska i dolaska (dep_time, arr_time, sched_dep_time, sched_arr_time). U ovoj fazi ekstrahiraju se svi ključni vremenski atributi te se parsiraju iz string formata u strukturirane komponente poput sati i minuta. Nakon ekstrakcije, podaci prolaze kroz transformaciju koja uključuje generiranje dodatnih analitičkih kategorija poput "time_of_day" (jutro, podne, večer) i "is_peak_hour" za identifikaciju špice prometa. Posebna pažnja posvećena je tehničkim atributima, poput surogat ključa (time Tk), koji omogućavaju efikasnu analizu operativnih obrazaca tijekom dana i optimizaciju letnih rasporeda.

```
16 • SELECT * FROM dim_time LIMIT 10;
```

	time Tk	dep_time	arr_time	sched_dep_time	sched_arr_time	hour	minute	time_of_day	is_peak_hour
1		04:46	06:18	05:00	06:48	5	0	Morning	0
2		04:46	06:36	05:00	06:40	5	0	Morning	0
3		04:47	06:14	05:00	06:48	5	0	Morning	0
4		04:48	06:24	05:00	06:40	5	0	Morning	0
5		04:48	06:35	05:00	06:48	5	0	Morning	0
6		04:48	06:48	05:00	06:51	5	0	Morning	0
7		04:49	06:20	05:00	06:40	5	0	Morning	0
8		04:49	06:20	2025-05-22	2025-05-22	5	0	Morning	0
9		04:50	06:33	05:00	06:48	5	0	Morning	0
10		04:50	06:34	05:00	06:48	5	0	Morning	0

Slika 12. Dimenzijska tablica dim_time

6.4. Dimenzijska tablica "dim_airline"

Proces izgradnje dimenzijske tablice "dim_airline" započinje prikupljanjem podataka o zrakoplovnim kompanijama iz izvornog CSV-a ili relacijske baze podataka. U ovoj fazi prikupljaju se svi ključni atributi poput koda prijevoznika (carrier), punog naziva aviokompanija (airline_name) i dodatnih identifikatora. Nakon ekstrakcije, podaci prolaze kroz transformaciju koja uključuje uklanjanje duplikata, standardizaciju naziva aviokompanija i popunjavanje eventualnih nedostajućih vrijednosti. Posebna pažnja posvećena je tehničkim atributima, poput surogat ključa (airline_tk), koji omogućavaju efikasno povezivanje s fact tablicom i praćenje promjena kroz vrijeme.

	airline_tk	carrier	airline_name
►	1	9E	Endeavor Air Inc.
	2	AA	American Airlines Inc.
	3	AS	Alaska Airlines Inc.
	4	B6	Jetblue Airways
	5	DL	Delta Air Lines Inc.
	6	EV	Expressjet Airlines Inc.
	7	F9	Frontier Airlines Inc.
	8	FL	Airtran Airways Corporation
	9	HA	Hawaiian Airlines Inc.
	10	MQ	Envoy Air

Slika 13. Dimenzijska tablica dim_airline

6.5. Dimenzijska tablica "dim_aircraft"

Proces izgradnje dimenzijske tablice "dim_aircraft" započinje prikupljanjem podataka o zrakoplovima iz izvornog CSV-a ili relacijske baze podataka, fokusirajući se na registracijske oznake zrakoplova (tailnum). U ovoj fazi ekstrahiraju se svi dostupni identifikatori letjelica te se uspostavljaju veze s odgovarajućim aviokompanijama. Nakon ekstrakcije, podaci prolaze kroz transformaciju koja uključuje čišćenje i standardizaciju registracijskih oznaka, uklanjanje duplikata i rješavanje nedostajućih vrijednosti korištenjem označavanja "UNKNOWN". Posebna pažnja posvećena je tehničkim atributima, poput surogat ključa (aircraft_tk), koji omogućavaju praćenje performansi specifičnih zrakoplova kroz vrijeme i analizu efikasnosti različitih letjelica u flotama aviokompanija.

	aircraft_tk	tailnum
▶	1	D942DN
	2	N0EGMQ
	3	N10156
	4	N102UW
	5	N103US
	6	N104UW
	7	N10575
	8	N105UW
	9	N107US
	10	N108UW

Slika 14. Dimenzijska tablica dim_aircraft

6.6. Dimenzijska tablica "dim_dep_delay"

Proces izgradnje dimenzijske tablice "dim_dep_delay" započinje prikupljanjem podataka o kašnjenjima polaska iz izvornih podataka, fokusirajući se na razloge kašnjenja (reason_dep_delay) i vremenska trajanja (dep_delay_time). U ovoj fazi ekstrahiraju se svi slučajevi kašnjenja s odgovarajućim uzrocima i vremenskim podacima. Nakon ekstrakcije, podaci prolaze kroz transformaciju koja uključuje mapiranje različitih razloga kašnjenja u standardizirane kategorije, kombiniranje razloga s vremenskim podacima i uklanjanje duplikata. Posebna pažnja posvećena je tehničkim atributima, poput surogat ključa (dep_delay_tk), koji omogućavaju detaljnu analizu uzroka operativnih problema i identifikaciju najčešćih faktora koji utječu na punktualnost polazaka letova.

	dep_delay_tk	reason	delay_time
►	1	Air Traffic Congestion	31
	2	Air Traffic Congestion	32
	3	Air Traffic Congestion	33
	4	Air Traffic Congestion	34
	5	Air Traffic Congestion	35
	6	Air Traffic Congestion	36
	7	Air Traffic Congestion	37
	8	Air Traffic Congestion	38
	9	Air Traffic Congestion	39
	10	Air Traffic Congestion	40

Slika 15. Dimenzijska tablica dim_dep_delay

6.7. Dimenzijska tablica "dim_arr_delay"

Proces izgradnje dimenzijske tablice "dim_arr_delay" započinje prikupljanjem podataka o kašnjenjima dolaska iz izvornih podataka, fokusirajući se na razloge kašnjenja (reason_arr_delay) i vremenska trajanja (arr_delay_time). U ovoj fazi ekstrahiraju se svi slučajevi kašnjenja dolaska s odgovarajućim uzrocima i vremenskim komponentama. Nakon ekstrakcije, podaci prolaze kroz transformaciju koja uključuje kategorizaciju razloga kašnjenja u standardizirane grupe, kombiniranje s vremenskim podacima o trajanju kašnjenja i eliminaciju duplikata. Posebna pažnja posvećena je tehničkim atributima, poput surogat ključa (arr_delay_tk), koji omogućavaju analizu faktora koji utječu na puntualnost dolazaka i razlikovanje između sistemskih problema polaska i dolaska letova.

	arr_delay_tk	reason	delay_time
►	1	Air Traffic Congestion	31
	2	Air Traffic Congestion	32
	3	Air Traffic Congestion	33
	4	Air Traffic Congestion	34
	5	Air Traffic Congestion	35
	6	Air Traffic Congestion	36
	7	Air Traffic Congestion	37
	8	Air Traffic Congestion	38
	9	Air Traffic Congestion	39
	10	Air Traffic Congestion	40

Slika 16. Dimenzijska tablica dim_arr_delay

6.8. Dimenzijska tablica "dim_route"

Proces započinje ekstrakcijom svih jedinstvenih kombinacija polazišnih i odredišnih aerodroma iz izvora. Nakon toga slijedi deduplikacija ruta i standardizacija geografskih podataka poput naziva gradova, zemalja i aerodroma. Svakoj ruti dodjeljuje se surogat ključ (routeTk), a izračunavaju se dodatni atributi poput udaljenosti u kilometrima. Podaci se učitavaju u tablicu "dim_route", što omogućava detaljno praćenje i analizu geografskih obrazaca letova kroz različite dimenzije.

	routeTk	origin	destination	departure_city	departure_country	departure_airport_name	destination_city	destination_country	destination_airport_name	distance
▶	1	EWB	ALB	Newark	United States	Newark Liberty International Airport	Albany	United States	Albany International Airport	143
	2	EWB	ANC	Newark	United States	Newark Liberty International Airport	Anchorage	United States	Ted Stevens Anchorage International Airport	3370
	3	EWB	ATL	Newark	United States	Newark Liberty International Airport	Atlanta	United States	Hartsfield Jackson Atlanta International Airport	746
	4	EWB	AUS	Newark	United States	Newark Liberty International Airport	Austin	United States	Austin Bergstrom International Airport	1504
	5	EWB	AVL	Newark	United States	Newark Liberty International Airport	Asheville	United States	Asheville Regional Airport	583
	6	EWB	BDL	Newark	United States	Newark Liberty International Airport	Hartford	United States	Bradley International Airport	116
	7	EWB	BNA	Newark	United States	Newark Liberty International Airport	Nashville	United States	Nashville International Airport	748
	8	EWB	BOS	Newark	United States	Newark Liberty International Airport	Boston	United States	Logan International Airport	200
	9	EWB	BQN	Newark	United States	Newark Liberty International Airport	Aguadilla	Puerto Rico	Rafael Hernández International Airport	1585
	10	EWB	BTB	Newark	United States	Newark Liberty International Airport	South Burlington	United States	Burlington International Airport	266

Slika 17. Dimenzijska tablica dim_route

7. Vizualizacija i poslovna analiza

U završnoj fazi projekta fokus je bio na vizualizaciji podataka i provođenju poslovne analize korištenjem alata **Power BI**. Ova točka pokazala se posebno zanimljivom jer je omogućila vizualno predstavljanje obrađenih i učitanih podataka. Vizualizacije igraju ključnu ulogu u procesu donošenja odluka jer omogućuju intuitivno razumijevanje složenih informacija i brzo prepoznavanje obrazaca.

Izradio sam različite **dashboarde**, koristeći operacije: Slice , Dice, Roll-up, Drill-down, Pivot. Pri čemu je svaki usmjeren na specifičan aspekt zrakoplovnih operacija. Time su obuhvaćene različite poslovne perspektive od sveukupne analize kašnjenja, do detaljnih prikaza performansi po aviokompanijama, rutama i vremenskim periodima

Svaki dashboard sadrži kombinaciju vizualnih prikaza grafikona, tablica i interaktivnih filtera koji prikazuju ključne operativne pokazatelje. Posebna pažnja posvećena je višedimenzionalnom analizi, omogućujući korisnicima da prate opće podatke o letovima, ali i da se usmjere na konkretne detalje koji ih zanimaju.

Dashboarde sam izradio tako da korisniku jasno prikazuju priču koju podaci o letovima govore – od uzroka kašnjenja i ključnih ruta, do usporedbe aviokompanija i sezonskih ili dnevnih obrazaca.

Kao prvo sam započeo sa povezivanjem svih tablica kako bi dao korisniku što bolju sliku sveukupnog projekta prilikom vizualizacije grafova.




Slika 18. Spajanje tablica radi u model view-u

7.1. Dashboard #1 – analiza letova po aviokompanijama

Prvi dashboard dizajniran je kao sveobuhvatan pregled aktivnosti aviokompanija u određenom vremenskom periodu. Prikazuje ključne informacije o broju letova po aviokompanijama, ukupnoj aktivnosti i operativnim pokazateljima.

Letovi po aviokompanijama



Ukupno letova

262K

Broj ruta

223

Total Routes

Letovi na vrijeme u (%)

78.50

Prosječno kašnjenje

180.98

Avg Delay

Ukupno aviokompanija

16

Slika 19. Sveobuhvatan pregled aktivnosti aviokompanija

U desnom dijelu dashboarda istaknuto je pet ključnih brojčanih vrijednosti (KPI):

Ukupno letova od 262K predstavlja volumen zračnog prometa, što ukazuje na značajan opseg avijacijske aktivnosti u analiziranom periodu. Ova brojka daje jasnu sliku o razmjerima analiziranog tržišta i služi kao temelj za sve daljnje analize.

Ukupno letova

262K

Slika 20. Ukupan broj letova svih aviokompanija

Broj ruta od 223 pokazuje raznolikost destinacija i povezanosti mreže letova. Ovaj podatak je važan jer ukazuje na geografsku pokrivenost i dostupnost različitih pravaca, što je ključno za procjenu povezanosti tržišta.

Broj ruta

223

Total Routes

Slika 21. Ukupan broj ruta svih aviokompanija

Prosječno točnost letova od 78.50 %

Letovi na vrijeme u (%)

78.50

Slika 22. Prosječno točnost letova

Prosječno kašnjenje od 180.98 (Avg Delay) dodatno naglašava problematiku kašnjenja u avioindustriji, što može ukazivati na sistemske izazove u upravljanju zračnim prometom ili operativnim procesima.

Prosječno kašnjenje

180.98

Avg Delay

Slika 23. Sveukupno prosječno kašnjenje aviokompanija

Ukupno aviokompanija od 16 pokazuje raznolikost tržišta s relativno velikim brojem operatora, što može ukazivati na konkurentno okruženje.


Ukupno aviokompanija

16

Slika 24. Ukupan broj aviokompanija

U glavnom vizualnom dijelu dashboarda ističe se horizontalni stupčasti graf koji prikazuje raspodjelu letova po aviokompanijama. **United Air Lines Inc.** dominira tržištem s najvećim brojem letova (preko 50K), što jasno pozicionira ovu kompaniju kao tržišnog lidera. Slijede **JetBlue Airways**, **ExpressJet Airlines Inc.** i **Delta Air Lines Inc.** s također značajnim brojem letova (između 40K-50K).

Letovi po aviokompanijama



Slika 25. Sveukupni prikaz letova po aviokompaniji

7.2. Dashboard #2 – OLAP operacije SLICE i DICE

Drugi dashboard dizajnirao sam za demonstraciju naprednih OLAP operacija koje omogućuju interaktivnu analizu podataka kroz različite dimenzije. Ovaj dashboard je posebno koristan za dubinsku analizu podataka jer omogućuje korisnicima da dinamički filtriraju i kombiniraju različite dimenzije prema svojim analitičkim potrebama.

OLAP operacije SLICE i DICE

Mjesec
month
1 12



Dan u tjednu
day_of_week

☒ Friday
☐ Monday
☐ Saturday
☐ Sunday
☐ Thursday
☐ Tuesday
☐ Wednesday

Aviokompanije
airline_name

☐ Airtran Airways Corporation
☐ Alaska Airlines Inc.
☐ American Airlines Inc.
☒ Delta Air Lines Inc.
☐ Endeavor Air Inc.
☐ Envoy Air
☐ Expressjet Airlines Inc.
☐ Frontier Airlines Inc.
☐ Hawaiian Airlines Inc.
☐ Jetblue Airways
☐ Mesa Airlines Inc.
☐ Skywest Airlines Inc.
☐ Southwest Airlines Co.
☐ United Air Lines Inc.
☐ Us Airways Inc.
☐ Virgin America

Ukupno letova

5525

Broj ruta

46

Total Routes

Letovi na vrijeme u (%)

81.94

Prosječno kašnjenje

76.57

Avg Delay

Ukupno aviokompanija

1

Slika 26. Vizualizacija Slice i Dice operacija

Dashboard prikazuje filtrirane rezultate koji reflektiraju specifičnu SLICE i DICE operaciju:

Ukupno letova: 5,525 što predstavlja Delta Air Lines operacije samo petkom kroz cijelu godinu

Broj ruta: 46 što pokazuje da Delta operira široku mrežu destinacija petkom, pokrivajući značajan dio ukupnih ruta dostupnih iz NYC aerodroma

Letovi na vrijeme: 81.94%, što ukazuje da Delta Air Lines ima bolje performanse puntualnosti petkom nego što je ukupni prosjek svih aviokompanija

Prosječno kašnjenje: 76.57 minuta, što pokazuje da Delta Air Lines ima kraća kašnjenja kada se dogode

Ukupno aviokompanija: 1 zbog filtriranja na samo Delta Air Lines

Dan u tjednu
day_of_week

☒ Friday

☐ Monday

☐ Saturday

☐ Sunday

☐ Thursday

☐ Tuesday

☐ Wednesday

Slika 27. Slice operacija

Temporalni SLICE: Odabrani su **petci** (Friday) kao specifični dan u tjednu

Aviokompanije
airline_name

☐ Airtran Airways Corporation

☐ Alaska Airlines Inc.

☐ American Airlines Inc.

☐ Delta Air Lines Inc.

☐ Endeavor Air Inc.

☐ Envoy Air

☐ Expressjet Airlines Inc.

☒ Frontier Airlines Inc.

☐ Hawaiian Airlines Inc.

☐ Jetblue Airways

☐ Mesa Airlines Inc.

☐ Skywest Airlines Inc.

☐ Southwest Airlines Co.


☐ United Air Lines Inc.

☐ Us Airways Inc.

☐ Virgin America

Slika 28. Slice operacija

Aviokompanijski SLICE: Odabrana je **Frontier Airlines Inc.** kao jedina aviokompanija za analizu



Slika 29. Vizualizacija rezultata Dice operacije

Rezultati Dice operacije: **DICE operacija:**

Kombinirao sam oba filtera istovremeno, što je rezultiralo analizom koja pokazuje "Kako Frontier Airlines operira(leti) petkom kroz cijelu godinu"

7.3. Dashboard #3 – OLAP operacije: ROLL-UP i DRILL-DOWN

Treći dashboard prikazuje OLAP operacije kroz hijerarhijsku analizu vremenskih podataka. Korisnik može prelaziti između godišnje, mjesečne i dnevne razine, što omogućuje analizu podataka na različitim dubinama.

Faza 1 - Godišnja razina:

year	Total Flights	Avg Delay
☐ 2013	261877	180.98
Total	261877	180.98

Slika 30. Drill-down, početna godišnja razina

Na početnoj (godišnjoj) razini prikazani su ukupni podaci za 2013. godinu – 261,877 letova i prosječno kašnjenje od 180.98 minuta. Ova razina daje opći pregled performansi bez detalja.

Faza 2 - DRILL-DOWN na mjesečnu razinu:

month	Total Flights	Avg Delay
1	21055	97.43
2	18926	96.26
3	22294	106.77
4	22055	111.35
5	22468	105.72
6	21599	126.27
7	22629	128.28
8	23118	103.03
9	21589	101.89
10	22924	88.04
11	21573	82.48
12	21647	109.17
Total	261877	180.98

Slika 31. Drill-down do mjesečne razine

Drill-down na mjesečnu razinu otkriva sezonske trendove i mjesečne varijacije. Ljetni mjeseci (lipanj, srpanj, kolovoz) bilježe veća kašnjenja, dok su listopad, studeni i prosinac najpunktualniji. Broj letova po mjesecima je relativno ujednačen.

Faza 3 - Daljnji DRILL-DOWN na dnevnu razinu:

day	Total Flights	Avg Delay
1	8635	87.81
2	8431	92.92
3	8891	78.12
4	8737	64.81
5	8484	83.28
6	8549	64.55
7	8546	89.14
8	8311	103.45
9	8192	82.40
10	8420	100.37
11	8788	89.14
12	8430	90.51
13	8723	83.53
14	8619	73.90
15	8903	66.64
16	8608	75.32
17	8762	86.70
18	8893	92.13
19	8656	87.88
Total	261877	180.98

Slika 32. Drill-down do dnevne razine

Daljnjim drill-downom moguće je analizirati podatke po danima. Prikaz omogućuje uvid u dnevne varijacije kašnjenja i prepoznavanje operativno izazovnih dana.

Roll-up operacija omogućuje povratak na višu razinu agregacije uz automatsko zbrajanje letova i ponovno izračunavanje prosječnih vrijednosti, čime se olakšava pregled i usporedba podataka.


year	Total Flights	Avg Delay
2013	261877	180.98
Total	261877	180.98

Slika 33. Roll-up operacija

7.4. Dashboard #4 – Operacija PIVOT

Četvrti dashboard prikazuje naprednu PIVOT operaciju u kombinaciji s filterom za destinaciju. Odabirom Denvera (DEN) kao ciljne destinacije, svi prikazi fokusirani su isključivo na letove iz NYC aerodroma prema Denveru, omogućujući detaljnu, ruta-specifičnu analizu.

Broj letova koji ide u DEN(Denver) iz svakog origin-a po mjesecima



Slika 34. Pivot operacija


Prema pivot analizi, LaGuardia (LGA) dominira s 2.923 letova prema Denveru od ukupno 5.730, a najviše letova evidentirano je između 17 i 18 sati, s utorkom i četvrtkom kao najaktivnijim danima. Dodatna analiza po aviokompanijama (npr. stabilan broj letova za Southwest) i aerodromima (LGA prednjači, JFK ima najmanje letova) omogućuje fokusiranu optimizaciju resursa i usporedbu performansi.

7.5. Dashboard #5 – detaljna analiza letova po aviokompanijama

Peti dashboard fokusirao sam na detaljnu analizu distribucije letova među aviokompanijama kako bih dobio uvid u tržišnu strukturu i dominaciju pojedinih operatera u NYC zračnom prostoru. Ovaj dashboard je posebno koristan za razumijevanje konkurentske pozicije i planiranje strategija za upravljanje aerodromskim resursima.

Detalji letova po aviokompaniji

Flights by Airline



Ukupno letova

262K

Broj ruta

223

Total Routes

Letovi na vrijeme u (%)

78.50

Prosječno kašnjenje

180.98

Avg Delay


Ukupno aviokompanija

16

Slika 35.. Detaljna analiza letova po aviokompanijama

Dashboard zadržava iste KPI pokazatelje kao i prvi (262K ukupno letova, 223 rute, 78.50% letova na vrijeme, 180.98 minuta prosječno kašnjenje i 16 aviokompanija), što omogućuje kontinuitet analize.

Letovi po aviokompanijama



Slika 36. Kružni graf koji prikazuje letove po aviokompanijama


Glavni vizualni element je **kružni graf "Letovi po aviokompanijama"** koji prikazuje postotnu distribuciju letova među aviokompanijama.

Iz grafa je jasno vidljivo neki od glavnih aviokompanija: **United Air Lines Inc.** dominira tržištem s **46K letova (17.67%)**, što ih čini najvećim operatorom u NYC zračnom prostoru.

JetBlue Airways slijedi s **43K letova (16.48%)**, pokazujući snažnu konkurentsku poziciju, dok **ExpressJet Airlines Inc.** drži treće mjesto s **41K letova (14.53%)**.

7.6. Dashboard #6 – Aviokompanije i sezonski trendovi

Šesti dashboard pruža pregled operativnih performansi aviokompanija kroz godinu, koristeći tri vizualizacije za analizu tržišta i sezonskih obrazaca.




Slika 37. Vizualizacija aviokompanija i mjesečnih trendova

Letovi po aviokompanijama

United Air Lines Inc. prednjači s 46,276 letova, potvrđujući tržišnu dominaciju. Slijede JetBlue i ExpressJet s uravnoteženim brojem operacija, dok manji prijevoznici imaju minimalnu prisutnost.

Letovi po aviokompanijama




Slika 38. Letovi po aviokompanijama

Letovi po mjesecima

Promet je stabilan tijekom godine (21K–23K letova mjesečno), s blagim padom u veljači i vrhuncima u kolovozu i listopadu. Takva ravnoteža omogućuje lakše planiranje resursa.


Ukupan broj letova po mjesecima



Slika 39. Ukupan broj letova po mjesecima

Mjesečni trendovi

Graf prikazuje sezonske obrasce: pad u veljači, rast do kolovoza, jesenski pad i blagdanski oporavak u prosincu. Ovi trendovi pomažu u planiranju operacija, održavanja i kapaciteta.



Slika 40. Mjesečni trend letova


7.7. Dashboard #7 – Analiza operativnih performansi

Ovaj dashboard pruža integrirani uvid u performanse aviokompanija u NYC prostoru kroz četiri ključne vizualizacije.


Letovi po aviokompanijama

United Air Lines Inc. dominira tržištem (~46K letova), a prate ih JetBlue, ExpressJet, Delta i American Airlines. Manji operateri imaju ograničen promet.


Letovi po aviokompanijama




Kašnjenja u vremenu



Mjesečni volumen letova




Letovi na vrijeme(%)



Slika 41. Operativne performance aviokompanija

Punktualnost letova

Gauge indikator prikazuje da je **84.13% letova** stiglo na vrijeme, što upućuje na dobru, ali ne i optimalnu operativnu točnost.




Slika 42. Postotak letova na vrijeme

Kašnjenja u vremenu

Linijski graf prikazuje prosječna kašnjenja po mjesecima:


Kašnjenja rastu tijekom proljeća i ljeta, s vrhuncima oko mjeseca 5–7. Najmanje kašnjenja bilježe se u jesen, posebno u mjesecu 10.



Slika 43. Kašnjenje letova u vremenu

Mjesečni promet po aviokompanijama

Stabilni udjeli velikih prijevoznika tijekom godine, uz sezonske varijacije ukupnog prometa (18K–23K letova mjesečno). Manji operatori ostaju na marginama tržišta.




Slika 44. Mjesečni volume letova


Ljetni mjeseci nose najveća kašnjenja i operativne izazove. Tržišna struktura ostaje stabilna, što olakšava planiranje i alokaciju resursa.

7.8. Dashboard #8 – Geografska analiza destinacija s interaktivnim filtriranjem

Osmi dashboard prikazuje naprednu geografsku analizu destinacija s mogućnostima interaktivnog filtriranja. Ovaj dashboard kombinira stupčasti graf najpopularnijih destinacija s interaktivnom kartom svijeta, omogućavajući korisnicima da vizualno razumiju globalnu mrežu povezanosti NYC aerodroma.



Slika 45. Geografska analiza



Na slici je prikazana geografska analiza letova ExpressJet Airlines Inc. tijekom srpnja do rujna, fokusirana na domaće rute srednje udaljenosti, s naglaskom na istočnu obalu SAD-a. Najviše letova bilo je prema Washingtonu (DCA), uz prosječno kašnjenje od 36,74 minute, a analiza omogućuje detaljan uvid pomoću filtara za aviokompaniju, mjeseca i udaljenost.

8. Zaključak

Kroz ovaj projekt uspješno sam napravio kompletnu bazu podataka i analitički sustav za podatke o letovima. Kombinirao sam Python za analizu podataka, Apache Spark za ETL procese, MySQL za bazu podataka i Power BI za grafove i dashboardove.

Apache Spark se pokazao kao odličan izbor za obradu velikih količina podataka - puno je brži od standardnih alata i može raditi s velikim fileovima kakvi se pojavljuju u avioindustriji. Star schema model koji sam dizajnirao omogućava različite vrste analiza, od osnovnih pregleda do detaljnih izvještaja. Sustav koji sam napravio može koristiti svatko tko radi u zrakoplovstvu - menadžeri mogu vidjeti gdje su problemi s kašnjenjima, koje su rute najproblematičnije, kako se performanse mijenjaju kroz godine, i slično. Power BI dashboardovi su jednostavni za korištenje, tako da ne treba biti programer da bi se dobili korisni podaci. Najveći izazov bio je dizajniranje dobre strukture podataka - trebao sam dobro analizirati dataset da vidim koje informacije su važne i kako ih najbolje organizirati. Spark je olakšao posao s velikim količinama podataka, a Power BI je omogućio stvaranje preglednih grafova. Za buduće poboljšanje, sustav bi se mogao proširiti s dodatnim podacima (npr. vremenske prilike, ekonomski pokazatelji), dodati bi se mogli modeli za predviđanje kašnjenja, ili napraviti real-time analiza podataka.

9. Literatura

- Kimball, R., Ross, M.** (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3rd Edition. John Wiley & Sons.
- Sharda, R., Delen, D., Turban, E.** (2018). *Business Intelligence, Analytics, and Data Science: A Managerial Perspective*. 4th Edition. Pearson.
- Inmon, W.H.** (2005). *Building the Data Warehouse*. 4th Edition. John Wiley & Sons.
- Han, J., Kamber, M., Pei, J.** (2012). *Data Mining: Concepts and Techniques*. 3rd Edition. Morgan Kaufmann.
- Provost, F., Fawcett, T.** (2013). *Data Science for Business*. O'Reilly Media.
- Liu, F., Yu, H.** (2020). *Flight Delay Prediction and Analysis: A Review*. *Journal of Advanced Transportation*, Hindawi.
- Apache Spark Documentation.** (2025). *Spark SQL, DataFrames and Datasets Guide*. [Internet], Dostupno na: <https://spark.apache.org/docs/latest/sql-programming-guide.html>
- Microsoft.** (2025). *Power BI Documentation*. [Internet], Dostupno na: <https://docs.microsoft.com/en-us/power-bi/>
- Kaggle.** (2025). *Flights Dataset*. [Internet], Dostupno na: <https://www.kaggle.com/datasets/mahoora00135/flights>
- Bureau of Transportation Statistics (BTS).** (2025). *Airline On-Time Performance Data*. [Internet], Dostupno na: https://www.transtats.bts.gov/OT_Delay/OT_DelayCause1.asp